



Universidad
Carlos III de Madrid

Grado en Ingeniería Informática

Curso 2020/2021

Redes de Neuronas Artificiales

Problema de Regresión

Predicción del precio medio de la vivienda en California

Autores:

Alba Reinders Sánchez
Alejandro Valverde Mahou

100383444
100383383

Índice

1. Introducción	3
2. Preparación de Datos	3
2.1. Normalización	3
2.2. Aleatorización	3
2.3. Separación en conjuntos de datos	3
3. Adaline	4
3.1. Experimentación	4
3.2. Resultados Obtenidos	4
3.3. Análisis	4
4. Perceptron Multicapa	4
4.1. Experimentación	4
4.2. Resultados Obtenidos	4
4.3. Análisis	4
5. Comparación de Modelos	4
6. Conclusiones	4

1. Introducción

El problema a resolver es la **predicción del precio medio de la vivienda en California**, usando dos modelos diferentes: *Adaline* y *Perceptron Multicapa*.

El *Adaline* es un modelo **lineal**, mientras que el *Perceptron Multicapa* es un modelo **no lineal**. El objetivo de esta práctica es realizar una comparativa entre estos dos modelos mediante la experimentación y análisis de los resultados, para averiguar cuál de los dos es capaz de encontrar la solución más cercana a la solución óptima.

2. Preparación de Datos

Los datos proporcionados son: *longitude*, *latitude*, *housingMedianAge*, *totalRooms*, *totalBedrooms*, *population*, *households*, *medianIncome*, ***medianHouseValue***.

La salida de los modelos deberá ser ***medianHouseValue*** en función del resto de atributos.

El conjunto de ejemplos proporcionados es de **17000**.

2.1. Normalización

El primer paso en el preprocesado de los datos es la **normalización**. Esta técnica consiste en acotar todos los datos en un rango de 0 a 1. Se ha decidido para este problema, normalizar exclusivamente los atributos de entrada, y no la salida, porque, experimentalmente, resulta en menos error.

La normalización de los datos se realiza cuando los distintos atributos de entrada no están en la misma escala, ya que tener atributos con escalas muy diferentes puede dar lugar al cálculo erróneo de los pesos, lo que deriva en modelos ineficaces.

La transformación lineal que se aplica a cada atributo es:

$$atr'_i = \frac{atr_i - \min(atr)}{\max(atr) - \min(atr)}$$

2.2. Aleatorización

Para evitar un entrenamiento inadecuado, es necesario otorgar a los modelos una lista de datos desordenados, o con orden aleatorio. De esta forma el modelo no se ajusta a un rango concreto de valores, que podrían darse seguidos si no se organizan aleatoriamente.

2.3. Separación en conjuntos de datos

Dado que este problema tiene una cantidad suficientemente grande de datos, se puede realizar la división del conjunto de datos en 3 subconjuntos:

- **Conjunto de Entrenamiento:**

Con él se realiza el aprendizaje (ajuste de pesos) del modelo. Es el conjunto más grande, pues tiene el 60 % de los datos (10200 instancias).

- **Conjunto de Test:**

Se usa para evaluar la precisión y capacidad de generalización del modelo. Este conjunto tiene el 20 % de los datos (3400 instancias).

- **Conjunto de Validación:**

Se usa para determinar los mejores hiperparámetros del modelo. Este conjunto tiene el 20 % de los datos (3400 instancias).

3. Adaline

El lenguaje de programación elegido para el desarrollo del algoritmo **ADALINE** ha sido *Python*.

3.1. Experimentación

Se ha decidido realizar distintos experimentos, tanto con salida normalizada como con salida no normalizada, con el objetivo de comprobar cuál ofrece mejores resultados. Además, para cada experimento, se han realizado varias pruebas para encontrar la razón o tasa de aprendizaje más adecuada en cada caso.

En lugar de elegir arbitrariamente un número de ciclos para cada experimento, se ha usado un criterio de parada más específico: el aprendizaje termina cuando el error en el conjunto de validación es mayor o igual que en los 4 ciclos anteriores.

Este criterio de parada es eficaz dado que ayuda a determinar automáticamente el momento en el que el algoritmo converge en un valor concreto, o comienza a tener sobreaprendizaje.

Los experimentos consistirán en ejecutar el algoritmo con una tasa de aprendizaje inicial de *0.5*, que se irá ajustando a lo largo de los experimentos hasta alcanzar la tasa que obtenga los resultados más adecuados.

3.2. Resultados Obtenidos

Salida Normalizada

Tabla de resultados obtenidos por experimento:

	Experimento 1	Experimento 2	Experimento 3	Experimento 4
Tasa aprendizaje	0.5	0.3	0.2	0.22
Ciclos	5	5	>100	5
Errores entrenamiento	0.1537454242037602	0.12999495781099646	???	0.11611209167890484
Errores validación	0.1510858340453369	0.1273892127623424	???	0.11891913389047042
Errores test	0.1493666202359257	0.12539101364386532	???	0.11445888742244138

Salida No Normalizada

3.3. Análisis

4. Perceptron Multicapa

4.1. Experimentación

4.2. Resultados Obtenidos

4.3. Análisis

5. Comparación de Modelos

6. Conclusiones