Universidad
Carlos III de Madrid

Grado en Ingeniería Informática

Curso 2020/2021

Redes de Neuronas Artificiales

Problema de Clasificación: Parte II

Clasificación de imágenes con Redes Convolucionales

Autores:

Alba Reinders Sánchez	*100383444*
Alejandro Valverde Mahou	*100383383*

Índice

1. Introducción

El problema consiste en clasificar imágenes donde las entradas de la red son directamente los píxeles de cada imagen. Se utiliza el conjunto de datos *CIFAR10*, compuesto por **60000** imágenes en color (3 canales, *RGB*) de **32x32** píxeles. El conjunto de datos se divide en 50000 imágenes para entrenamiento y 10000 para test.

Hay un total de **10 clases** con 6000 imágenes por clase, por lo que en este caso las clases sí están balanceadas, las diferentes clases son:

- 0 → *airplane*
- 1 → *automobile*
- 2 → *bird*
- 3 → *cat*
- 4 → *deer*
- 5 → *dog*
- 6 → *frog*
- 7 → *horse*
- 8 → *ship*
- 9 → *truck*

El objetivo de la práctica es entrenar diferentes arquitecturas de **Perceptrón Multicapa** y **Redes de Neuronas Convolucionales** para analizar cómo influyen sus hiperparámetros en la resolución del problema de clasificación. Además de comparar sus resultados para comprobar cuál de las dos arquitecturas es más efectiva.

2. Diseño, entrenamiento y evaluación del PM

Inicialmente se intenta resolver este problema con el método de 'fuerza bruta'. Es decir, se aplana la información de los píxeles de las imágenes de entrada en un único vector y se entrena un **Perceptrón Multicapa** con estas entradas.

Para estudiar la eficacia de este acercamiento se realiza una pequeña experimentación probando distintas arquitecturas de red:

Arquitectura	***epochs***	***Accuracy* entrenamiento**	***Accuracy* test**	***Loss* entrenamiento**	***Loss* test**
(50)	25	0.5552	0.4743	1.2606	1.5040
(25)	21	0.5039	0.4493	1.4128	1.5678
(100)	16	0.5543	0.4922	1.9684	1.4483
(100,100)	30	0.6442	0.5045	0.9995	1.4618
(100, 100, 100)	23	0.5900	0.5081	1.1478	1.4276

Tabla Experimentos *PM*

En cada uno de los experimentos se ajusta manualmente el número de *epochs* óptimos para encontrar los mejores resultados posibles.

Se parte de la arquitectura dada en el tutorial y se prueba a modificar sus hiperparámetros a partir de ella. Primero se prueba a disminuir el número de neuronas, lo que no genera mejores resultados. Por tanto se prueba a aumentarlas y el *accuracy* mejora, entonces se decide añadir una capa oculta más y también genera mejores resultados.

Como último experimento se configura una red con 3 capas ocultas de 100 neuronas cada una, este obtiene los mejores resultados. Sin embargo, el *accuracy* en test que alcanza se queda estancado entorno a 0,5.

Tras esta experimentación se puede concluir que aumentar la complejidad de la arquitectura de la red, tanto en capas ocultas como en neuronas, hace que genere mejores resultados. Aunque no consigue superar un umbral, por lo que la utilización del *PM* para resolver este problema no es del todo eficaz.

En las gráficas siguientes se puede ver la evolución de los valores de *accuracy* y *loss* de entrenamiento y test durante el aprendizaje de la red para el mejor experimento, que es el último de los realizados.

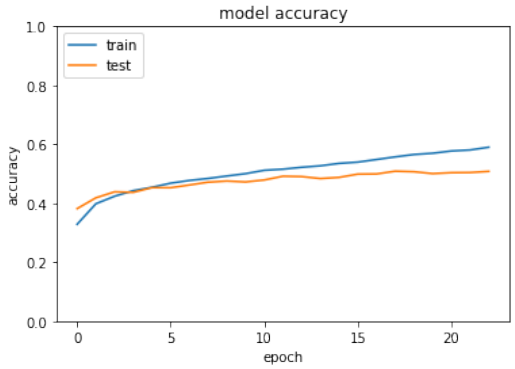

Accuracy en entrenamiento y test del *PM*

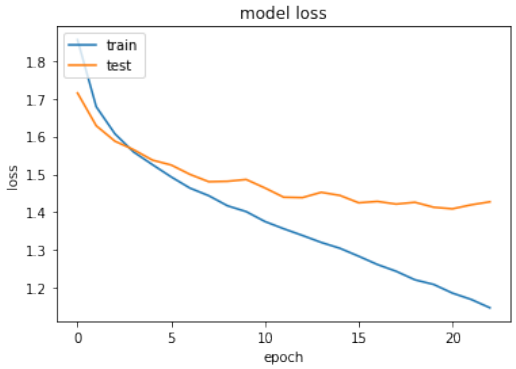

Loss en entrenamiento y test del *PM*

Se puede ver que el *accuracy* en entrenamiento seguiría subiendo mientras que en test se queda estancado en 0.5, esto se puede observar mejor en la siguientes gráficas donde se han dejado 100 *epochs* para demostrar este comportamiento.

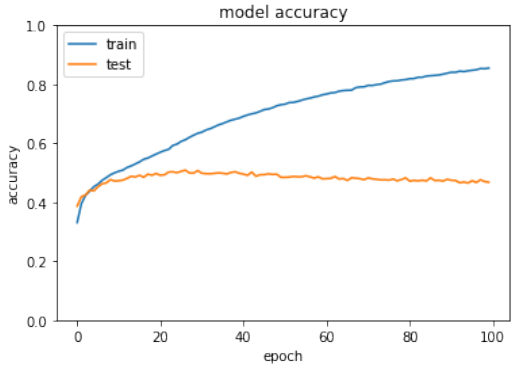

Accuracy en entrenamiento y test del *PM*

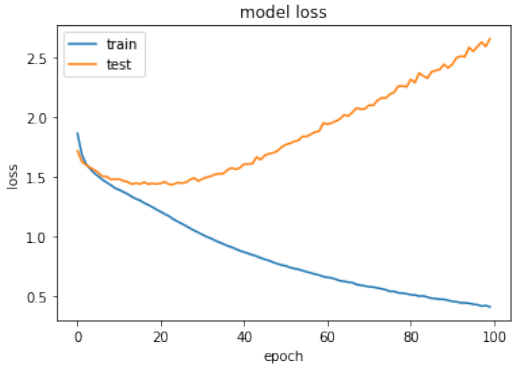

Loss en entrenamiento y test del *PM*

A continuación se muestra la **matriz de confusión** resultante de este experimento. Además se añade el *recall* para comprobar la precisión sobre cada una de las clases.

Real \Predicho	**Airplane**	**Auto**	**Bird**	**Cat**	**Deer**	**Dog**	**Frog**	**Horse**	**Ship**	**Truck**	***Recall***
Airplane	569	22	58	21	35	9	44	31	129	82	0.57
Auto	41	516	15	25	14	7	45	21	84	232	0.52
Bird	86	10	334	83	142	55	177	64	29	20	0.33
Cat	26	12	66	322	65	141	216	51	37	64	0.32
Deer	58	5	102	62	457	30	177	64	31	14	0.46
Dog	21	11	80	211	60	321	145	85	34	32	0.32
Frog	10	4	32	53	86	27	733	18	13	24	0.73
Horse	43	11	44	69	99	70	52	530	17	65	0.53
Ship	91	44	8	16	20	10	28	18	675	90	0.68
Truck	41	121	7	34	15	19	34	48	57	624	0.62

Matriz de confusión mejor experimeto *PM*

En esta matriz se puede apreciar que algunas clases como *Frog* o *Ship* le resultan más fácil de clasificar al modelo. Mientras que otras clases como *Bird*, *Cat* o *Dog* le resultan mucho más complicadas de diferenciar. En la gráfica siguiente se puede ver de forma visual el *recall* de las clases:

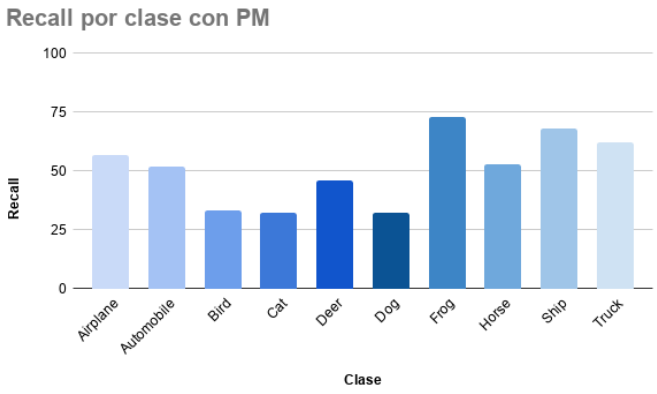

Gráfica *recall* por clase del *PM*

3. Diseño, entrenamiento y evaluación de la CNN

Una vez se ha experimentado con el *PM* se intenta resolver este problema con una **Red Convolucional**. En este caso se aplican capas de convolución antes de aplanar la información.

Para estudiar la eficacia de esta aproximación se realiza la siguiente experimentación probando distintas arquitecturas. En cada uno de los experimentos, al igual que en el caso anterior, se ajusta manualmente el número de *epochs* óptimos para encontrar los mejores resultados posibles.

Nota: la definición de la arquitectura sigue la siguiente terminología: $(n_1(k_1, Dd_1), n_2(k_2, Dd_2), ...)$ *donde* n_i *indica el número de filtros,* k_i *el tamaño del kernel y* d_i *el dropout*

Arquitectura	*epochs*	*Accuracy* entrenamiento	*Accuracy* test	*Loss* entrenamiento	*Loss* test
(16(3))	20	0.6960	0.6106	0.8588	1.1403
(16(3, D0.3))	47	0.7127	0.6479	0.8101	1.0243
(32(3))	28	0.7447	0.6121	0.7041	1.2311
(16(2))	14	0.7007	0.6269	0.8590	1.1205
(16(2, D0.3))	7	0.6558	0.6308	0.9927	1.0706
(16(3, D0.3), 16(3, D0.3))	20	0.7259	0.7006	0.7813	0.9050
(16(3, D0.3), 16(3, D0.3), 16(3, D0.3))	44	0.7261	0.6311	0.7775	1.0658
(16(3, D0.5), 16(3, D0.5))	43	0.7110	0.6401	0.8234	1.0642
(16(3, D0.2), 16(3, D0.2))	50	0.7640	0.7149	0.6670	0.8450
(16(3, D0.1), 16(3, D0.1))	13	0.7311	0.6952	0.7690	0.8952
(16(4, D0.2), 16(4, D0.2))	29	0.7716	0.7116	0.6413	0.8298
(16(5, D0.2), 16(5, D0.2))	65	0.8179	0.7226	0.5039	0.8294
(16(6, D0.2), 16(6, D0.2))	31	0.7860	0.7107	0.6018	0.8393

Tabla Experimentos *CNN*

Se parte de la arquitectura dada en el tutorial y se prueba a modificar sus hiperparámetros a partir de ella. Tras probar esta configuración inicial se decide probar a añadir una capa de *Dropout* de 0.3 para comprobar si mejoran los resultados, se puede ver que mejoran bastante.

Después se prueba a duplicar el número de filtros, pero esto no influye demasiado así que se puede decir que este cambio no supone una gran difencia y no es decisivo a la hora de mejorar los resultados. Por lo que se vuelven a establecer 16 filtros pero se prueba a disminuir el tamaño del kernel a 2. Esto tampoco parece influir en gran medida sobre los resultados y por ello se prueba a añadir una capa de *Dropout*, lo que produce una ligera mejora. Dado que cambiar los hiperparámetros de una única capa convolucional no hace que aumente el *accuracy* en test, se decide añadir una segunda capa convolucional. Ambas con 16 filtros, tamaño de kernel 3 y *Dropout* de 0.3, con esta arquitectura se consigue una mejora considerable.

Como aumentar el número de capas convolucionales ha dado buenos resultados, se prueba a añadir una tercera capa. Pero como esto hace que empeoren los resultados se decide seguir con la experimentación usando sólo dos capas convolucionales. Se puede concluir que aumentar demasiado la complejidad de la red hace que los resultados dejen de ser buenos.

A continuación se prueba a modificar el *Dropout*, primero a aumentarlo. Como se ve que no mejora, se prueba a diminuirlo, obteniendo un mejor resultado con un *Dropout* de 0.2. Tras esto se prueba a aumentar el tamaño del kernel lo que hace que se obtengan valores muy similares. Finalmente se consigue encontrar la mejor configuración con un kernel de tamaño 5, obteniendo un *accuracy* en test de 0.7226.

Sobre este mejor experimento se va a realizar dos subexperimentos adicionales utilizando diferentes optimizadores para comprobar la influencia de cada uno de ellos. Así como las gráficas de evolución de los valores de *accuracy* y *loss* durante el aprendizaje de la red.

Optimizador	***Accuracy* entrenamiento**	***Accuracy* test**	***Loss* entrenamiento**	***Loss* test**
Adam	0.8179	0.7226	0.5039	0.8294
RMSprop	0.7932	0.6913	0.5969	0.9287
Adagrad	0.5675	0.5564	1.2356	1.3065

Tabla mejor experimento *CNN* con diferentes optimizadores

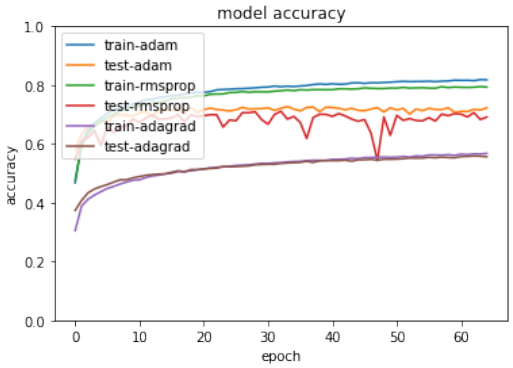

Accuracy en entrenamiento y test del *CNN*

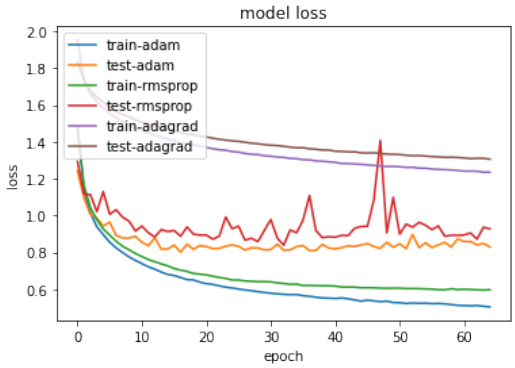

Loss en entrenamiento y test del *CNN*

Como se puede ver en la tabla y en las gráficas anteriores, el mejor optimizador es **Adam**, seguido de **RMSprop** con muy poca diferencia y por último **Adagrad** con valores muy inferiores al resto.

Se observa en las gráficas que los valores obtenidos con RMSprop son mucho más erráticos que con Adam, por lo que a pesar de que la diferencia entre ambos parecía pequeña, es mejor Adam porque tiene un comportamiento más estático.

La tabla siguiente muestra la **matriz de confusión** corespondiente a los resultados del mejor experimento, junto con el *recall* de cada clase:

Real \Predicho	**Airplane**	**Auto**	**Bird**	**Cat**	**Deer**	**Dog**	**Frog**	**Horse**	**Ship**	**Truck**	***Recall***
Airplane	735	12	50	19	17	10	12	11	83	51	0.73
Auto	14	813	4	9	5	2	9	4	27	113	0.81
Bird	67	6	524	78	125	76	67	27	13	17	0.52
Cat	26	8	50	556	81	151	62	22	26	18	0.56
Deer	24	2	44	40	764	25	35	41	18	7	0.76
Dog	16	7	35	193	55	603	22	51	8	10	0.60
Frog	8	4	23	69	68	28	784	2	11	3	0.78
Horse	20	5	29	36	73	57	4	755	5	16	0.76
Ship	44	22	13	13	6	3	6	4	849	40	0.85
Truck	33	57	5	8	10	8	2	9	25	843	0.84

Matriz de confusión mejor experimeto *CNN*

En este caso se puede apreciar que sigue teniendo especial dificultad para clasificar las clases *Bird*, *Cat* o *Dog*, pero ahora clasifica con mucha más confianza otras clases, como pueden ser *Ship*, *Truck* o *Automobile*. En la siguiente gráfica se puede ver visualmente el *recall* por clase:

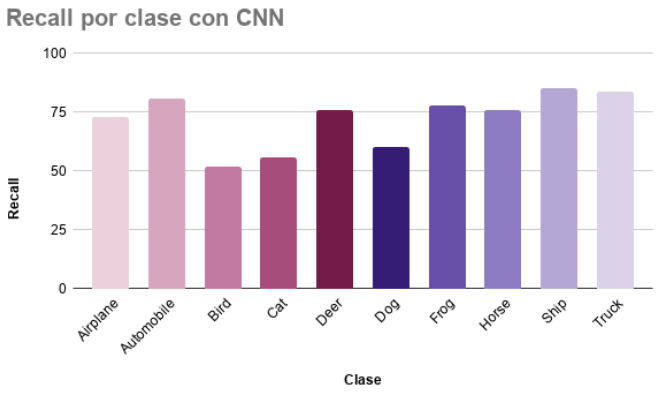

Gráfica *recall* por clase del *CNN*

4. Comparación PM y CNN

En este apartado se van a comparar los dos acercamientos propuestos en la práctica, así como evaluar sus resultados, y analizar de forma breve las soluciones encontradas.

Primero es necesario comparar los mejores resultados obtenidos. Esto se puede ver en la siguiente tabla:

Arquitectura	***epochs***	***Accuracy* entrenamiento**	***Accuracy* test**	***Loss* entrenamiento**	***Loss* test**
PM (100, 100, 100)	23	0.5900	0.5081	1.1478	1.4276
CNN (16(5, D0.2), 16(5, D0.2))	65	0.8179	0.7226	0.5039	0.8294

Tabla comparativa mejores modelos

Se puede apreciar que el *accuracy* del modelo con *CNN* es mucho superior al del *PM*. Concretamente en el *accuracy* en test, *PM* sólo consigue un valor de **0.5081** mientras que *CNN* consigue **0.7226**. Esta medida es la verdaderamente importante a la hora de determianr cómo de bueno es un modelo. A continuación se muestra también una comparativa del *recall* obtenido por cada modelo:

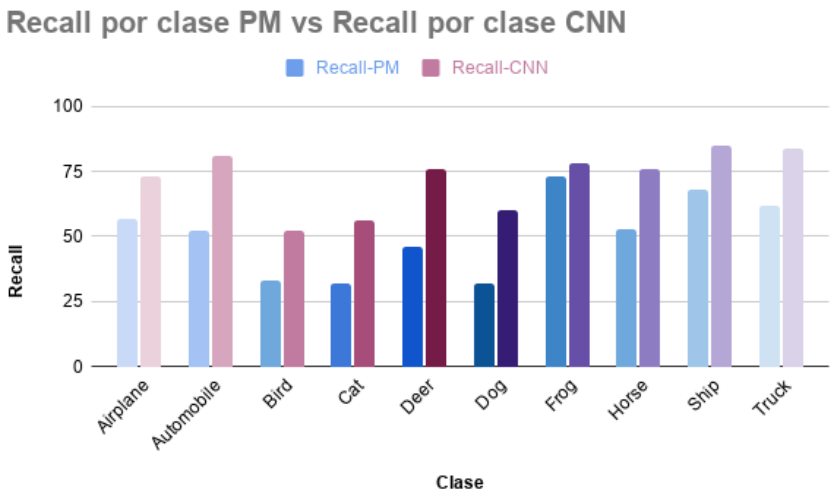

Gráfica *recall* por clase del *PM* vs. *CNN*

Se ve que, tal y como se esperaba, el modelo del *CNN* tiene mejores resultados en todos los casos. Tras esta breve comparativa se puede apreciar que los modelos de *Redes Convolucionales* son mucho más efectivos que los modelos de *Perceptrón Multicapa* a la hora de realizar clasificación sobre imágenes.

5. Conclusión

Esta práctica ha sido de gran utilidad para aprender a realizar clasificación sobre imágenes utilizando dos técnicas distintas con redes de neuronas: un acercamiento más ingénuo, el *Perceptrón Multicapa*, que recibe directamente la información de los píxeles, y otro acercamiento más especializado, a través de las *Redes Convolucionales*.

Se ha podido ver que la efectividad a la hora de resolver este tipo de problemas para cada acercamiento es diferente, siendo las *Redes Convolucionales* las que mejor son capaz de resolverlos.

Se ha estudiado la influencia de los hiperparámetros en la resolución del problema, así como realizar una experimentación que ha ido modificando estos parámetros hasta encontrar la configuración que mejor resolvía el problema.

A pesar de que los resultados obtenidos no superan el 75 % de instancias bien clasificadas, y que no parece un resultado demasiado bueno, hay que tener en cuenta que es un problema en el que hay que determinar 10 clases distintas de imágenes de muy baja resolución. El caso base en este problema sería una precisón del 10 %, por lo que se considera que un **72 %** de instancias bien clasificadas es una buen resultado.